AIPF — AI Performance Framework

Uma linguagem executiva para medir IA em produção.

O AIPF (AI Performance Framework) foi criado para preencher uma lacuna do mercado: não existia um modelo estruturado que conectasse produto, operação, finanças e governança numa linguagem que executivos e times técnicos pudessem compartilhar.

Este documento apresenta o Framework completo: os 5 pilares, suas métricas, perguntas executivas, exemplos práticos e como o AIPF se integra ao processo de implementação da AIVANTE como gate entre piloto e escala.

5	30	15
Pilares de avaliação	Métricas operacionais	Perguntas executivas

CONTEXTO

Por que o AIPF existe

O mercado brasileiro de IA atravessa um ponto de inflexão. 88% das organizações já usam IA no dia a dia, mas apenas 39% reportam impacto real no lucro operacional. A barreira não é mais tecnológica ou financeira — é de engenharia e medição.

O PROBLEMA

Empresas implementam IA sem definir como medir sucesso. Quando chega a hora de decidir se escalam, a resposta é baseada em opinião, não em dados. Resultado: expansão prematura ou abandono de projetos que estavam funcionando.

A SOLUÇÃO

O AIPF fornece uma estrutura objetiva com 5 pilares que cobrem o ciclo completo: da produtividade ao custo, do valor econômico à confiabilidade, da governança à compliance. Um scorecard único para tomar a decisão de escalar.

> *"O AIPF não é um diagnóstico inicial. Ele é aplicado quando a IA já está em produção. Mede o resultado real e gera a base de dados para decidir se faz sentido expandir."*
>
> Bruno Lunardi, Fundador da AIVANTE

Quando o AIPF é aplicado

Fase 1 Entendimento → **Fase 2** Piloto → **GATE** AIPF → **Fase 3** Escala

O Framework entra após o piloto estar em produção. Ele avalia os resultados reais nos 5 pilares e gera o scorecard que orienta a decisão: escalar, otimizar ou pivotar.

ARQUITETURA

Os 5 pilares do AIPF

Cada pilar avalia uma dimensão crítica da operação de IA. Juntos, formam uma visão completa que conecta produtividade, economia, valor de negócio, confiabilidade e governança.

01 Intelligence Throughput — Vazão de Inteligência

A IA está produzindo trabalho útil concluído? Ou está gerando atividade sem resultado? Este pilar mede a capacidade real de converter agentes e tokens em tarefas finalizadas com qualidade aceitável.

02 Token ROI — Custo por Resultado

Quanto custa cada resultado entregue? Não o token unitário, mas o custo completo incluindo modelo, revisão humana, retrabalho e correções. A eficiência econômica real da operação.

03 Value Conversion Rate — Conversão em Valor

A IA está gerando valor econômico real ou apenas artefatos? Receita, margem, capacidade liberada, custo evitado. A ponte entre consumo de inteligência e impacto no negócio.

04 Operational Reliability — Confiabilidade Operacional

O negócio pode depender desta IA no dia a dia? Uptime, latência, fallback, observabilidade. A diferença entre um experimento e uma operação que o negócio confia.

05 Governance & Compliance — Governança e Compliance

Quem responde por quê? O processo é auditável? Rastreabilidade, gestão de risco, LGPD, políticas de uso. A capacidade de escalar sem criar dívida regulatória.

PILAR 01

01 Intelligence Throughput

Vazão de Inteligência

Capacidade de converter agentes, modelos e tokens em trabalho útil concluído, com prioridade clara, desenho operacional e qualidade aceitável. O foco não é volume de atividade, é resultado entregue.

PERGUNTAS EXECUTIVAS

- A IA está aumentando capacidade real de execução?
- O fluxo está fluindo ou apenas gerando mais atividade?
- A validação humana virou gargalo?

MÉTRICAS

- Tarefas concluídas por workflow
- % itens resolvidos IA + revisão humana
- Taxa de aceitação em primeira passada
- Tempo médio de fila por tarefa
- Retrabalho por workflow/agente
- Capacidade simultânea efetiva

EXEMPLOS PRÁTICOS

→ **Atendimento:** mais tickets processados por semana sem aumento de headcount, preservando SLA.

→ **Jurídico:** contratos de baixo risco triados e sumarizados antes da revisão final.

→ **Operações:** solicitações repetitivas fluem com IA + revisão humana, reduzindo backlog.

ERRO COMUM

Medir volume de prompts/tokens e não trabalho concluído com qualidade.

PILAR 02

02 Token ROI

Custo por Resultado

Eficiência econômica do uso de IA: otimização do custo total por resultado entregue, e não apenas do custo unitário por token. Inclui o custo de revisão humana, retrabalho e correções.

PERGUNTAS EXECUTIVAS

- Estamos usando o modelo certo para cada tarefa?
- O custo está otimizado no processo completo (incluindo revisão humana)?
- Onde a IA está cara e sem retorno proporcional?

MÉTRICAS

Cost per Outcome | Custo por tarefa concluída | Mix de modelos por workflow | Taxa de escalonamento para premium | Custo de retrabalho | Custo total do processo (IA + humano)

EXEMPLOS PRÁTICOS

→ **Comercial:** modelos leves para triagem; premium apenas para casos complexos e exceções.

→ **Regulatório:** triagem econômica, sumário intermediário, análise crítica apenas com impacto material.

→ **Backoffice:** roteamento por complexidade reduz custo sem perda de qualidade.

ERRO COMUM

Otimizar custo por token e piorar custo por resultado (retrabalho, erro, latência).

PILAR 03

03 Value Conversion Rate

Taxa de Conversão em Valor

Taxa de conversão entre consumo de inteligência e impacto econômico real. Receita, margem, capacidade liberada, redução de ciclo, custo evitado. A ponte entre o que a IA produz e o que o negócio captura.

PERGUNTAS EXECUTIVAS

- A IA está gerando valor de negócio ou apenas artefatos?
- O ganho operacional está sendo capturado?
- O uso de IA está se convertendo em resultado mensurável?

MÉTRICAS

% saídas de IA efetivamente utilizadas | % tarefas assistidas que chegam ao fim | Redução de ciclo convertida em capacidade | Receita incremental atribuível | Cost avoidance | Impacto em SLA, conversão, retenção, margem

EXEMPLOS PRÁTICOS

→ **Vendas:** drafts só geram valor quando viram propostas enviadas, fechamentos e receita.

→ **Operação interna:** resumos só capturam valor quando viram ações executadas com responsável e prazo.

→ **Atendimento:** redução de tempo só vira valor quando melhora SLA, retenção ou NPS.

ERRO COMUM

Parar na adoção sem fechar a ponte até resultado econômico.

PILAR 04

04 Operational Reliability

Confiabilidade Operacional

Confiabilidade da operação em produção: qualidade, latência, fallback, observabilidade, escalabilidade e previsibilidade. A diferença entre um experimento e uma operação na qual o negócio pode confiar no dia a dia.

PERGUNTAS EXECUTIVAS

- O negócio pode depender dessa operação de IA no dia a dia?
- A solução se mantém estável sob carga?
- Existe plano de contingência quando há falha?

MÉTRICAS

Disponibilidade / uptime | Latência p50 / p95 / p99 | Taxa de sucesso por etapa | Fallback rate e fallback success rate | Taxa de incidentes e regressões | MTTR (tempo médio de recuperação)

EXEMPLOS PRÁTICOS

→ **Atendimento digital:** em picos, mantém latência aceitável e aciona contingência quando integração falha.

→ **Operação regulada:** updates entram com testes de regressão, logs e runbooks.

→ **Produtos internos:** alertas evitam descoberta de falhas apenas por reclamação do usuário final.

ERRO COMUM

Produção com mentalidade de experimento — sem SLO, sem observabilidade, sem owner.

PILAR 05

05 Governance & Compliance

Governança e Compliance

Capacidade de escalar IA com rastreabilidade, responsabilização, gestão de risco, políticas de uso e aderência regulatória. Governança não é burocracia — é o que diferencia IA corporativa de IA amadora. Fundamental para LGPD e PL 2338/2023.

PERGUNTAS EXECUTIVAS

- Quem responde por quê?
- O processo é auditável?
- Os controles são proporcionais ao risco do caso de uso?

MÉTRICAS

- % workflows com trilha de auditoria
- % prompts/templates versionados
- % workflows com revisão humana definida
- Cobertura de classificação de dados sensíveis
- Taxa de violações de política
- Catálogo de modelos/agentes aprovados

EXEMPLOS PRÁTICOS

→ **RH:** regras claras, revisão humana mandatória e critérios documentados.

→ **Jurídico/Financeiro:** rastrear origem, versão de modelo, validação humana e dados processados.

→ **Compliance:** casos de uso classificados por risco com controles proporcionais.

ERRO COMUM

Adicionar governança apenas depois da expansão (dívida de risco).

ENTREGÁVEL

O Scorecard AIPF

Ao final da avaliação, o AIPF gera um scorecard que consolida a performance do piloto nos 5 pilares. Este documento é a base para a decisão de escalar.

O QUE O SCORECARD CONTÉM

- ✓ **Avaliação por pilar** — Score e status de cada um dos 5 pilares com evidências
- ✓ **Métricas operacionais** — Dados reais coletados durante o piloto (custos, latência, throughput, etc.)
- ✓ **KPIs executivos** — Tradução das métricas técnicas em linguagem de negócio (ROI, capacidade, SLA)
- ✓ **Gaps identificados** — Onde o piloto precisa de otimização antes de escalar
- ✓ **Recomendação** — Escalar, otimizar ou pivotar — com justificativa baseada em dados
- ✓ **Roadmap de expansão** — Próximos processos priorizados por impacto e viabilidade

Três resultados possíveis

ESCALAR

Piloto validado nos 5 pilares. ROI comprovado. Governança adequada. Recomendação de expandir para novos processos priorizados pelo scorecard.

OTIMIZAR

Resultado positivo mas com gaps em 1-2 pilares. Recomendação de ajustar antes de escalar: custo, confiabilidade ou governança precisam de atenção.

PIVOTAR

Piloto não entregou resultado suficiente para justificar expansão. Dados indicam necessidade de redefinir escopo, processo ou abordagem técnica.

> *"A expansão para novos processos é discutida como próximo passo com escopo e investimento definidos separadamente — baseados em dados reais, não em suposições."*

PRÓXIMO PASSO

Quer aplicar o AIPF na sua operação?

O primeiro passo é entender o seu cenário. Uma conversa de 30 minutos para mapear seu momento e definir juntos por qual fase começar.

Conversa exploratória

contato@aivante.com.br
linkedin.com/company/aivante

AIVANTE

Engenharia de IA para Empresas