AIPF — AI Performance Framework

Guia operacional para levar IA do piloto à escala
com engenharia, métricas e governança.

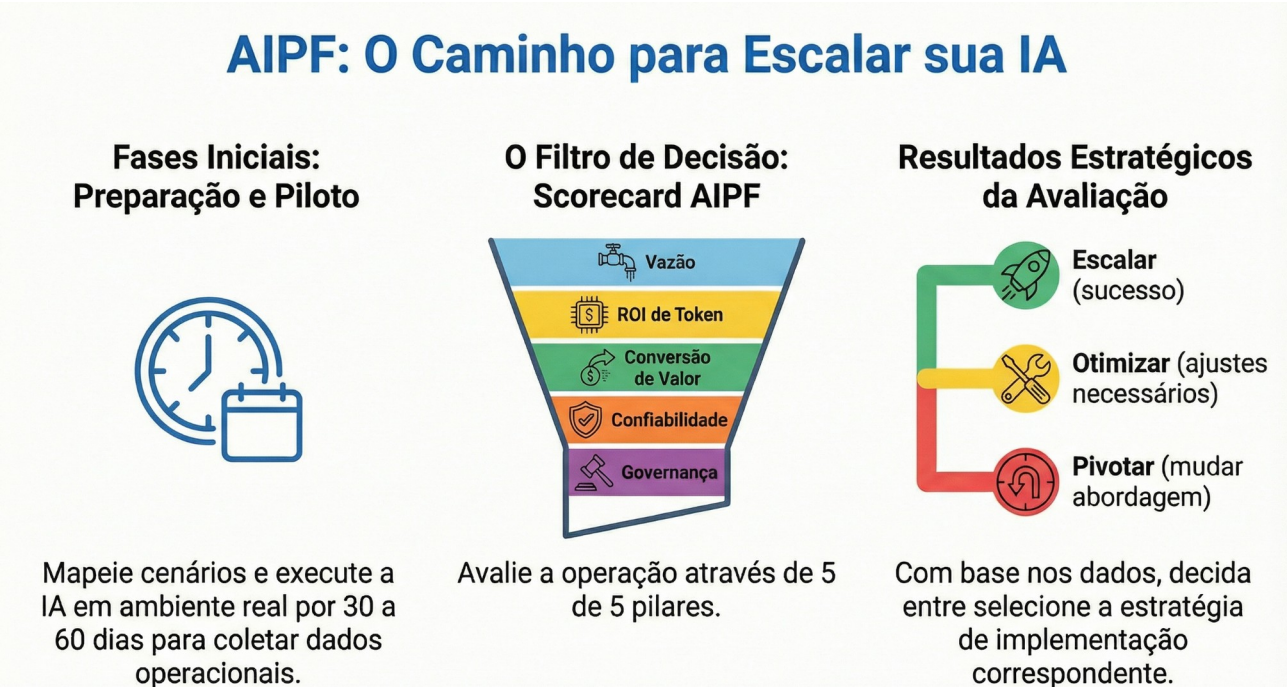

Infográfico: do piloto ao gate de decisão (Scorecard AIPF) e à estratégia de escala.

Sumário

1. Visão executiva
2. Por que a maioria dos projetos de IA falha
3. O processo em 3 fases (Entendimento, Piloto e Escala)
4. Orquestração corporativa: Trust Architecture
5. Scorecard AIPF: os 5 pilares de performance
6. Como medir na prática: instrumentação, Evals e observabilidade
7. Interpretação do scorecard: Escalar, Otimizar ou Pivotar
8. Casos de uso de alto impacto
9. Timeline do piloto (6 semanas)
10. Insights de mercado e riscos (2025–2026)
11. Perguntas frequentes (FAQ)
12. Apêndices: templates e glossário

1. Visão executiva

A AIPF (AI Performance Framework) organiza a implementação de IA como um processo de engenharia: um piloto em ambiente real gera dados operacionais; em seguida, um scorecard em 5 pilares valida o desempenho e define a estratégia correta (escalar, otimizar ou pivotar).

Quando usar

Use este guia quando você já tem (ou vai construir) um piloto de IA em produção e precisa transformar experimentação em decisão executiva baseada em dados: custo, qualidade, confiabilidade e risco.

O que você obtém ao final

- Um piloto funcional em escopo controlado, com travas de segurança e integração mínima com sistemas reais.
- Telemetria e evidências (custos, latência, taxas de sucesso, retrabalho, aprovação humana).
- Scorecard AIPF com avaliação dos 5 pilares e recomendação objetiva: escalar, otimizar ou pivotar.
- Plano de ação priorizado para corrigir gargalos e um roadmap para expansão.

Princípios do método

- IA em produção é probabilística: trate o modelo como um componente não-confiável dentro de um sistema confiável.
- Otimização deve ser por resultado (cost per outcome), não por atividade (tokens, prompts, volume de mensagens).
- Governança e controles entram desde o piloto: não existe escala sem rastreabilidade e responsabilidade.
- Toda melhoria precisa ser testável (Evals) e observável (telemetria) para evitar regressões.

2. Por que a maioria dos projetos de IA falha

O principal fator de falha é a intenção vaga: tentar automatizar processos complexos com instruções amplas, sem limites, sem validação e sem telemetria. Isso cria risco operacional, custo imprevisível e perda de confiança.

Falhas recorrentes observadas em operações corporativas

13. Alucinação e ausência de validação: o sistema aceita respostas incorretas e propaga erros.
14. Custos de API fora de controle: modelos premium são usados onde não agregam valor proporcional.
15. Sem visibilidade de performance: não há clareza de onde a IA gera valor versus onde gera retrabalho.
16. Loops infinitos de correção: fluxos mal desenhados exigem intervenção constante das equipes.
17. Governança entrando tarde: controles e compliance só aparecem após incidentes.
18. Perda de confiança do time: baixa confiabilidade reduz adoção e mata o ROI.

Regra prática

Se você não consegue responder com números 'quanto custa', 'quanto entrega' e 'quanto falha', você ainda está em modo experimento — e não em modo operação.

3. O processo em 3 fases

O processo é modular: você entra pela fase que faz sentido para seu estágio. A Fase 2 (Piloto) é a primeira entrega em produção; o AIPF é o gate de decisão; a Fase 3 (Escala) só começa com evidências consistentes.

Visão geral das fases

Fase	Objetivo	Atividades-chave	Entregáveis	Sinais de saída (pronto para avançar)
1. Entendimento	Selecionar o processo certo e desenhar o piloto com métricas de sucesso.	Mapear processos/stack; priorizar caso de uso; desenhar arquitetura; definir KPIs; estimar custo/timeline.	Mapa de processos; arquitetura do piloto; critérios de sucesso; estimativa de custo e cronograma.	Caso de uso priorizado; dados e integrações mínimas identificadas; KPIs definidos.
2. Piloto	Colocar um workflow em produção com travas, integração mínima e observabilidade.	Prompts e arquitetura de confiança; HITL; integrações; roteamento de modelos; deploy; telemetria.	Workflow em produção; painel de observabilidade; dataset de Evals; runbook básico; treinamento do time.	Operação estável (SLOs mínimos); dados coletados por 30–60 dias; evidências de custo/qualidade.
Gate: Scorecard AIPF	Avaliar performance real nos 5 pilares e decidir próximos passos.	Coletar métricas; pontuar pilares; identificar gargalos; plano de correção/escala.	Scorecard; KPIs executivos; recomendação (escalar/otimizar/pivotar) e roadmap.	Decisão justificada por dados; riscos conhecidos; plano de ação aprovado.
3. Escala	Expandir para novos workflows com previsibilidade de custo, performance e governança.	Priorizar novos casos; padronizar arquitetura; governança; otimização contínua; monitoramento.	Workflows adicionais; scorecards comparativos; roadmap atualizado; relatórios executivos.	Portfolio de workflows monitorado; métricas comparáveis; governança operacionalizada.

Fase 1: Entendimento

Mapeia cenário atual, identifica o processo com maior potencial e desenha o primeiro workflow de IA. O objetivo é reduzir risco: escolher o caso certo, com dados e integrações viáveis, e definir métricas de sucesso.

Entregáveis típicos

- Mapa de processos candidatos (alto impacto x viabilidade).
- Arquitetura do piloto (componentes, integrações, gates e telemetria).
- Definição de KPIs: operacionais e executivos.
- Estimativa de custo (IA + revisão humana) e timeline.

Fase 2: Piloto

Constrói um workflow em produção em escopo controlado. A prioridade é confiabilidade: travas (HITL), validações, roteamento de modelos por complexidade e observabilidade desde o dia 1.

Dados necessários para o gate AIPF

- Logs de execução por etapa (sucesso/falha, tempo, fallback).
- Custos por tarefa aceita (cost per outcome) e por etapa.
- Qualidade: taxa de aceitação, retrabalho, erros críticos e incidentes.
- Governança: trilha de auditoria, versionamento de prompts/templates e classificação de dados.

Gate: Scorecard AIPF

Após 30–60 dias de operação (ou volume mínimo suficiente), o scorecard consolida resultados e orienta a decisão com base nos 5 pilares. O gate evita que a empresa escale um piloto instável ou sem ROI.

Fase 3: Escala

Com o piloto validado, a escala expande para novos processos usando padrões de arquitetura, métricas comparáveis e governança operacionalizada. O objetivo é previsibilidade: custo, performance e risco controlados em portfólio.

4. Orquestração corporativa: Trust Architecture

O AIPF parte do princípio de zero-trust para modelos: a IA produz sugestões, mas o sistema valida, roteia, registra e impede que falhas virem incidentes. Em vez de 'chatbots', o foco é workflow: entradas -> validação -> execução -> evidência.

Os 4 pilares da orquestração

4.1 Decomposição de domínio (Domain Translation)

Automatizar departamentos é vago. Automatizar fluxos é preciso. A decomposição traduz requisitos de negócio em etapas pequenas, com entradas/saídas claras, limites de contexto e critérios de aceite.

- Defina o objeto do trabalho (ticket, contrato, proposta, solicitação) e o estado final desejado.
- Quebre o fluxo em etapas com 'contrato de interface': entradas permitidas, saída esperada, validações.
- Crie taxonomias (tipos de caso, níveis de risco, exceções) para roteamento consistente.

4.2 Zero-Trust + Human-in-the-Loop (HITL)

Em fluxos críticos, a IA pesquisa, analisa e rascunha; o sistema exige aprovação humana antes de avançar. A aprovação humana deve ser desenhada para não virar gargalo: revisão por amostragem, exceções ou risco.

- Defina quais etapas exigem revisão obrigatória (ex.: decisões regulatórias, financeiro, jurídico).
- Implemente gates de aprovação com critérios claros (checklist) e logs de justificativa.
- Use 'risk routing': casos de baixo risco podem ter revisão amostral; alto risco, revisão total.

4.3 Token Economics (Cost per Outcome)

Otimizar por token é insuficiente. O objetivo é custo total por resultado aceito, incluindo revisão humana, retrabalho e latência. Roteamento multi-modelo reduz custo sem perder qualidade.

- Use modelos leves para triagem, classificação e estruturação.
- Reserve modelos premium para raciocínio complexo e exceções.
- Monitore escalonamento para premium e retrabalho como custos ocultos.

4.4 Evals e Observabilidade (telemetria contínua)

Sem testes automatizados, cada ajuste de prompt/modelo vira risco de regressão. Evals criam disciplina: toda mudança precisa provar melhora em métricas de qualidade e segurança do workflow.

- Dataset de casos reais (anonimizados) + casos sintéticos de borda (edge cases).
- Testes de regressão antes de deploy: qualidade, segurança, PII, consistência.
- Painéis com métricas operacionais (SLOs), custos e alertas de falha.

5. Scorecard AIPF: os 5 pilares de performance

O scorecard transforma performance de IA em linguagem executiva. Ele consolida métricas em 5 pilares e orienta a decisão de continuidade com evidências. Cada pilar deve ser avaliado em maturidade (1–5).

Padrão de scoring sugerido (1–5)

1 = inexistente/incipiente | 2 = reativo e manual | 3 = mínimo operacional | 4 = consistente e escalável | 5 = otimizado e governado por dados.

Pilar 01 — Intelligence Throughput (Vazão de Inteligência)

Definição: Capacidade de converter agentes, modelos e tokens em trabalho útil concluído, com qualidade aceitável.

Perguntas executivas

- A IA está aumentando capacidade real de execução?
- O fluxo está fluindo ou só gerando mais atividade?
- A validação humana virou gargalo?

Métricas recomendadas

Métrica	Como interpretar
Tarefas concluídas	Itens finalizados por dia/semana/mês por workflow.
Taxa de aceitação 1ª passada	% de saídas aceitas sem retrabalho significativo.
Retrabalho	% de itens devolvidos / reprocessados.
Tempo em fila	Tempo médio aguardando revisão/aprovação por tipo de tarefa.
Concurrency efetiva	Capacidade simultânea com qualidade (não apenas threads).

Ações típicas para melhorar o score

- Reduzir etapas; tornar entradas mais estruturadas; melhorar roteamento por tipo de caso.
- Revisão por exceção (risk routing) em vez de revisão total.
- Criar checklists de aceitação e UI de revisão que acelerem o humano.

Pilar 02 — Token ROI (Custo por Resultado)

Definição: Eficiência econômica do uso de IA: custo total por resultado entregue, e não custo unitário por token.

Perguntas executivas

- Estamos usando o modelo certo para cada tarefa?
- O custo está otimizado no processo completo (inclui revisão humana)?
- Onde a IA está cara e sem retorno proporcional?

Métricas recomendadas

Métrica	Como interpretar
Cost per Outcome	Custo por resultado aceito (IA + revisão humana + retrabalho).
Mix de modelos	% de uso por classe (leve/intermediário/premium).
Escalonamento para premium	Quando e por que casos 'sobem' para modelo caro.
Custo de retrabalho	Custo adicional causado por refazer tarefas.
Latência x custo	Trade-off entre tempo e custo em etapas críticas.

Ações típicas para melhorar o score

- Roteamento multi-modelo por complexidade; cache; redução de contexto e tokens.
- Separar etapas: classificação barata -> raciocínio caro apenas quando necessário.
- Rever promps/formatos que aumentam retrabalho (custo oculto).

Pilar 03 — Value Conversion Rate (Conversão em Valor)

Definição: Taxa de conversão entre consumo de inteligência e impacto econômico real (receita, margem, capacidade liberada).

Perguntas executivas

- A IA está gerando valor de negócio ou apenas artefatos?
- O ganho operacional está sendo capturado?
- O uso de IA se converte em resultado mensurável?

Métricas recomendadas

Métrica	Como interpretar
% de saídas utilizadas	Saídas que viram ação real no fluxo (enviadas, registradas, executadas).
% de tarefas que chegam ao fim	Taxa de conclusão do workflow após assistência da IA.
Redução de ciclo	Tempo poupado convertido em capacidade (backlog/SLA).
Receita incremental	Impacto atribuível em conversão, upsell ou

	retenção.
Cost avoidance	Custos evitados (horas, multas, retrabalho, perdas).

Ações típicas para melhorar o score

- Definir 'última milha': integração com sistemas e responsabilidades claras.
- Amarrar IA a um owner e a um KPI de negócio (SLA, conversão, margem).
- Garantir que o output é consumível: estrutura, campos, trilha, acionáveis.

Pilar 04 — Operational Reliability (Confiabilidade Operacional)

Definição: Confiabilidade da operação em produção: qualidade, latência, fallback, observabilidade e previsibilidade.

Perguntas executivas

- O negócio pode depender disso no dia a dia?
- A solução se mantém estável sob carga?
- Existe plano de contingência quando há falha?

Métricas recomendadas

Métrica	Como interpretar
Disponibilidade	Uptime do workflow e dependências.
Latência p50/p95/p99	Tempo de resposta por etapa e fim a fim.
Taxa de sucesso por etapa	Onde falha e por quê (integração, validação, modelo).
Fallback rate	% de vezes que precisa contingência e sucesso da contingência.
MTTR	Tempo médio de recuperação após falhas/incidentes.

Ações típicas para melhorar o score

- Definir SLOs mínimos e alertas; adicionar retries e circuit breakers.
- Criar runbooks e ownership operacional.
- Testes de regressão e canary releases para mudanças de prompt/modelo.

Pilar 05 — Governance & Compliance (Governança e Compliance)

Definição: Capacidade de escalar IA com rastreabilidade, responsabilização, gestão de risco e aderência regulatória.

Perguntas executivas

- Quem responde por quê?
- O processo é auditável?
- Os controles são proporcionais ao risco do caso de uso?

Métricas recomendadas

Métrica	Como interpretar
% com trilha de auditoria	Logs completos: entrada, saída, versão, aprovador, decisão.
% com versionamento	Prompts/templates/modelos versionados e aprovados.
Classificação de dados	Cobertura de PII/sensíveis e políticas de retenção.
Políticas de uso	Taxa de violações e tratamento.
Catálogo aprovado	Lista de modelos/agentes autorizados por risco.

Ações típicas para melhorar o score

- Definir matriz de risco e controles mínimos por classe de caso.
- Implementar versionamento e aprovação para prompts e datasets.
- Logs e retenção compatíveis com auditoria e LGPD.

6. Como medir na prática: instrumentação, Evals e observabilidade

O scorecard depende de evidências. A recomendação é instrumentar desde o piloto, com um esquema mínimo de logs, métricas e testes automatizados. Sem isso, a avaliação vira subjetiva.

6.1 Telemetria mínima por execução

- Identificador único por execução (request_id) e por item de trabalho (work_item_id).
- Metadados do modelo: provider, modelo, versão, temperatura, tools usadas.
- Contagem de tokens: input/output por etapa e total.
- Latência: por etapa e fim a fim (p50/p95/p99).
- Status por etapa: sucesso, falha, retry, fallback.
- Indicador de revisão humana: aprovado/rejeitado + motivo + tempo de revisão.
- Classificação de risco e tipo de caso (para roteamento e auditoria).

6.2 Evals: disciplina de melhoria contínua

Evals são testes automatizados que medem qualidade e segurança do workflow. O objetivo é evitar regressões: toda mudança de prompt/modelo deve passar por um conjunto de casos e métricas antes do deploy.

- Golden set: amostra de casos reais (anonimizados) com rótulos de saída esperada.
- Edge cases: casos de borda (ambiguidade, input incompleto, tentativas de jailbreak, PII).
- Métricas: taxa de acerto, precisão/recall quando aplicável, consistência, segurança e compliance.
- Testes de regressão: comparar nova versão vs baseline e bloquear deploy se piorar métricas críticas.

6.3 Observabilidade e painéis

- Painel executivo: Cost per Outcome, Value Conversion Rate, tendência de throughput e decisão sugerida.
- Painel operacional: latência, falhas por etapa, fallback, incidentes, MTTR e backlog.
- Painel de governança: trilha de auditoria, versionamento, uso de dados sensíveis e violações.

Checklist de prontidão para aplicar o scorecard

1) Piloto rodando em produção com volume mínimo ou janela de 30–60 dias; 2) logs e métricas coletados; 3) amostra de Evals disponível; 4) regras de aprovação humana definidas; 5) owner operacional nomeado.

7. Interpretação do scorecard: Escalar, Otimizar ou Pivotar

O scorecard não é um troféu; é um filtro de decisão. A recomendação estratégica depende de padrões mínimos e do perfil de risco do caso de uso.

Regras de gate recomendadas (padrão)

- Se Governança & Compliance < 3: não escalar. Corrigir antes de expandir.
- Se Confiabilidade Operacional < 3: não escalar. Estabilizar, criar SLOs e runbooks.
- Se Value Conversion Rate < 3: otimizar a última milha (integração, adoção, responsabilidade) antes de escalar.
- Se Token ROI < 3: revisar roteamento multi-modelo e custo oculto de retrabalho.
- Escalar somente quando os pilares críticos atingirem mínimo operacional e houver plano de manutenção.

Matriz simples de decisão

Cenário	Padrão de scores	Decisão	Foco imediato
Piloto promissor, instável	Valor >=3, Token ROI >=3, Confiabilidade <3	Otimizar (estabilizar)	SLOs, fallback, regressão, runbook, alertas
Alta qualidade, baixo valor capturado	Confiabilidade >=3, Governança >=3, Conversão <3	Otimizar (adoção/integração)	Última milha: integração, responsabilidades, métricas de negócio
Caro e com retrabalho	Token ROI <3, Throughput <3	Otimizar (arquitetura/custo)	Roteamento de modelos, entradas estruturadas, reduzir retrabalho
Bom em tudo, pronto para portfólio	Todos >=3 e tendência positiva	Escalar	Padronizar arquitetura, catalogar casos, governança em escala
Sem aderência ao problema	Conversão <3 e Throughput <3 mesmo após ajustes	Pivotar	Revisar caso de uso, dados, processo-alvo e estratégia

8. Casos de uso de alto impacto

A maior geração de valor costuma ocorrer onde há alto volume, regras conhecidas e atrito operacional: triagem, extração, classificação, sumarização e roteamento para decisão humana.

Exemplos de workflows e métricas

Marketing & Conteúdo em escala

Métricas comuns:

- Volume de conteúdo gerado
- Tempo de aprovação
- Consistência de marca

Legal & Contratos

Métricas comuns:

- Contratos triados/semana
- Tempo até revisão final
- Taxa de falso positivo

Operações & Backoffice (ERP/SAP)

Métricas comuns:

- Tempo de fechamento
- Retrabalho eliminado
- Custo evitado

Atendimento técnico nível 2

Métricas comuns:

- Tempo médio de resolução
- Taxa de escalonamento
- Satisfação do cliente

Comercial & Propostas

Métricas comuns:

- Taxa de conversão
- Tempo de ciclo comercial
- Custo por proposta aprovada

Compliance & Regulatório

Métricas comuns:

- Custo por alerta útil

- Tempo até parecer
- Cobertura de rastreabilidade

9. Timeline do piloto (ciclo de 6 semanas)

O piloto é desenhado para entregar evidência rápida com risco controlado. O foco é um único processo e um único workflow, com telemetria desde o início.

Semanas 1–2: Arquitetura & MVP

- Mapear o processo atual e definir o objeto do trabalho.
- Definir System Prompts e critérios de aceite por etapa.
- Setup do ambiente de desenvolvimento e primeiro agente funcionando.
- Definir esquema mínimo de logs e dataset inicial de Evals.

Semanas 3–4: Trust & HITL

- Conectar fluxo de ponta a ponta com gates de aprovação humana.
- Testes de alucinação, edge cases e calibração de prompts.
- Implementar validações estruturais (schemas) e políticas de dados.
- Documentar exceções e criar playbooks básicos.

Semanas 5–6: Deploy & Orquestração

- Integração com ferramentas reais (ERP/CRM/Teams/Slack/Jira).
- Roteamento multi-modelo e otimização de token economics.
- Painel de observabilidade e alertas mínimos.
- Treinamento do time e definição de ownership operacional.

Pós-deploy: Operação e preparação do scorecard

- Operar 30–60 dias (ou volume mínimo) para coletar dados confiáveis.
- Rodar Evals contínuos e corrigir regressões.
- Consolidar métricas e aplicar o Scorecard AIPF.
- Decidir: escalar, otimizar ou pivotar, com roadmap.

10. Insights de mercado e riscos (2025–2026)

A seção abaixo consolida indicadores de mercado frequentemente citados em relatórios e pesquisas sobre adoção de IA no Brasil e no mundo. Use como contexto estratégico — não como base única de decisão.

10.1 Adoção e investimento

- Crescimento de investimento em TI e IA: aumento de orçamento e priorização de automação.
- Queda de custo de processamento e maior acesso a modelos: a barreira é menos tecnologia e mais engenharia.
- Diferença entre adoção e impacto em lucro: muitas iniciativas não capturam valor por falta de processo.

10.2 Tendências técnicas

- Migração de assistentes passivos para agentes e workflows orquestrados.
- RAG e uso de dados proprietários como padrão para ancoragem e redução de alucinação.
- Engenharia de contexto e avaliação contínua substituindo ajustes ad-hoc de prompt.

10.3 Governança e risco

- Shadow AI: uso não autorizado de ferramentas com dados sensíveis aumenta risco de LGPD e incidentes.
- Necessidade de zero-trust, redaction de PII e trilha de auditoria desde o piloto.
- Regulação em evolução: controles proporcionais ao risco e documentação consistente.

11. Perguntas frequentes (FAQ)

Como funciona o processo? Preciso começar pela Fase 1?

Você entra pela fase que faz sentido para o seu momento. Quem está explorando IA tende a começar pelo Entendimento. Quem já tem um caso de uso definido pode ir direto para o Piloto. O ponto de entrada ideal depende de maturidade, dados e integrações.

Quando o Scorecard AIPF é aplicado?

O Scorecard é aplicado quando o workflow já está em produção, após o piloto. Ele mede resultado real nos 5 pilares e orienta a decisão de escalar, otimizar ou pivotar.

Quanto tempo leva para ter um workflow em produção?

O ciclo típico do piloto é de ~6 semanas (arquitetura/MVP, travas e testes, deploy e integração). A duração varia com complexidade do processo e integrações.

Como reduzir o risco de 'alucinação'?

A base é Trust Architecture: validações estruturais, RAG quando aplicável, gates de aprovação humana (HITL) em fluxos críticos e Evals automáticos para bloquear regressões.

Como controlar custos?

O controle é por resultado: cost per outcome. Use roteamento multi-modelo por complexidade, reduza retrabalho com entradas estruturadas e monitore escalonamento para modelos premium.

Quais sistemas podem ser integrados?

A abordagem é agnóstica: ERP/CRM, plataformas de dados, clouds e ferramentas de produtividade. As integrações necessárias são avaliadas na fase de entendimento do workflow.

Serve para empresas que ainda não têm IA?

Sim. O método permite começar com um caso de uso priorizado, construir um piloto em produção e só então decidir expansão com base em evidências.

Apêndice A — Template: Use Case Brief (1 página)

- Processo-alvo e dor: descreva o problema operacional e o impacto.
- Objeto do trabalho: o que entra e o que sai (inputs/outputs).
- Critérios de sucesso: métricas de negócio e operacionais.
- Risco e governança: dados sensíveis, revisão humana, auditoria.
- Integrações: sistemas necessários (fonte, destino, autenticação).
- Custos: estimativa IA + revisão humana; volume esperado.
- Escopo do piloto: o que entra / o que fica fora (guardrails).

Apêndice B — Template: Scorecard AIPF (rubrica 1–5)

Use a rubrica abaixo para padronizar avaliação entre workflows.

Pilar	1	2	3	4	5
Throughput	Sem medição; retrabalho alto	Mede volume, não conclusão	Mede conclusão e aceitação	Fluxo consistente e previsível	Otimizado por dados e prioridade
Token ROI	Custo desconhecido	Mede tokens apenas	Mede cost per outcome	Roteamento multi-modelo	Otimização contínua e automações
Conversão em valor	Saídas não viram ação	Adoção parcial	Valor mensurável em KPI	Valor consistente e escalável	Valor otimizado e atribuído
Confiabilidade	Sem SLO/alertas	Reativo	SLO mínimo + logs	Runbooks + regressão	Operação madura (canary, MTTR baixo)
Governança	Sem trilha/controles	Controles informais	Trilha e versionamento mínimo	Matriz de risco + auditoria	Governança em portfólio e compliance robusto

Apêndice C — Checklist de dados e privacidade

- Inventário de dados: origem, sensibilidade, retenção e quem acessa.
- Redaction de PII/segredos antes do modelo quando aplicável.
- Logs: o que armazenar, por quanto tempo e com que controles.
- Avaliação de risco por caso de uso e controles proporcionais.

Apêndice D — Glossário

Termo	Definição
Cost per Outcome	Custo total por resultado aceito (IA + revisão humana + retrabalho).
Evals	Testes automatizados para medir qualidade, segurança e regressão de um workflow de IA.
HITL	Human-in-the-Loop: gate de revisão/aprovação humana em etapas críticas.
RAG	Retrieval-Augmented Generation: ancoragem em dados proprietários para reduzir alucinação.
SLO	Service Level Objective: meta de confiabilidade/latência/sucesso para operação.